

PROYECTO FINAL

ANÁLISIS DE VENTAS Y PREDICCIÓN DE VENTAS FUTURAS

Análisis de datos para la toma de
decisiones estratégicas



Ali Vega

Cloud Computing / Data Analytics



2026




Proyecto Final


Tendencia de Ventas



Ventas por Categoría



Ventas por Región



OBJETIVO DEL PROYECTO



El objetivo de este proyecto fue **analizar información de ventas** de productos de consumo utilizando herramientas de análisis de datos y visualización.



A través del uso de diferentes tecnologías, se buscó identificar **tendencias, categorías** con mejor desempeño y **patrones** de comportamiento en los datos.



Además, se aplicaron modelos básicos de predicción para estimar posibles **ventas futuras** y apoyar la toma de **decisiones estratégicas**.



HERRAMIENTAS UTILIZADAS



Excel

Exploración y limpieza inicial de datos, creación de tablas dinámicas y análisis preliminar.



SQL Server

Diseño de base de datos, consultas SQL y extracción de información clave.



Python

Limpieza y transformación de datos, análisis exploratorio, visualizaciones y modelos de predicción.



Looker Studio

Diseño de dashboards interactivos para visualizar el desempeño de ventas.




AWS

Almacenamiento de datos en la nube, catalogación y consultas con Athena.

ARQUITECTURA DEL PROYECTO

El proyecto sigue un flujo de datos integral que abarca desde la extracción y transformación de la información hasta su visualización y análisis para la toma de decisiones.





EXPLORACIÓN EN EXCEL

Los datos fueron explorados en Excel mediante tablas dinámicas y gráficos para identificar tendencias, regiones con mayores ventas y comportamiento general de los productos.



¿Qué se analizó?

Tendencias de ventas, comportamiento semanal, regiones con mayor desempeño y productos destacados.



¿Qué permitió?

Identificar patrones comerciales relevantes y facilitar la comprensión inicial del comportamiento de ventas dentro del dataset.

1. VENTAS POR REGIÓN

Etiquetas de fila	Suma de TOTAL_VALUE_SALES
TOTAL AUTOS AREA 1	714249.979
TOTAL AUTOS AREA 2	1188796.15
TOTAL AUTOS AREA 3	808565.357
TOTAL AUTOS AREA 4	677435.996
TOTAL AUTOS AREA 5	1153335.538
TOTAL AUTOS AREA 6	983957.571
TOTAL AUTOS SCANNING MEXICO	5521428.32
Total general	11042859.99

Ventas por región



- Se identificó que algunas regiones concentran una mayor participación en las ventas totales, mostrando diferencias importantes en el desempeño comercial.

2. TENDENCIA SEMANAL DE VENTAS

Etiquetas de fila	Suma de TOTAL_VALUE_SALES
13-22	148453.79
14-22	117980.87
15-22	125641.56
16-22	126244.58
17-22	120403.25
18-22	159051.57
19-22	136655.26
20-22	124661.48
21-22	130404.35
22-22	153556.80
23-22	122674.77
24-22	120611.66
25-22	128914.97
26-22	122945.16
27-22	151846.08
28-22	128042.33
29-22	141761.37
30-22	123275.12
32-22	123052.28




- Las ventas muestran fluctuaciones semanales constantes, con algunos periodos de crecimiento y disminución a lo largo del tiempo.

3. PROMEDIO SEMANAL POR REGIÓN

Etiquetas de fila	Suma de TOTAL_UNIT_AVG_WEEKLY_SALES
TOTAL AUTOS AREA 1	128718.312
TOTAL AUTOS AREA 2	180553.221
TOTAL AUTOS AREA 3	181328.12
TOTAL AUTOS AREA 4	154650.229
TOTAL AUTOS AREA 6	183337.888
TOTAL AUTOS SCANNING MEXICO	526291.492
Total general	1322200.495

Promedio semanal por región




- El promedio semanal de ventas varía entre regiones, indicando diferencias en la demanda y desempeño comercial.

4. TOP PRODUCTOS

Etiquetas de fila	Suma de TOTAL_VALUE_SALES
00000750000639	1146496.632
00000750000622	1139233.387
00000750000615	656545.668
7501025402051	491075.222
7501017900143	399994.779
7501025405212	241281.14
7501025405214	241498.884
7501025405090	235784.387
7501025405151	198011.454
7501025405106	175110.993

Top productos



- Algunos productos generan una proporción considerablemente mayor de ventas en comparación con el resto del catálogo.



HALLAZGOS PRINCIPALES



Se identificaron diferencias relevantes entre regiones.



Algunos productos concentran gran parte de las ventas.



Las ventas muestran patrones temporales semanales.



SQL SERVER

Consultas Comerciales – Parte 1

Se utilizaron consultas SQL para analizar información de ventas, identificar regiones con mejor desempeño y calcular métricas comerciales relevantes.



1. VENTAS POR REGIÓN

```
1 - SELECT
2     REGION,
3     SUM(CAST(TOTAL_VALUE_SALES AS FLOAT)) AS TOTAL_VENTAS
4 FROM FACT_SALES
5 GROUP BY REGION
6 ORDER BY TOTAL_VENTAS DESC;
```

Resultados Mensajes

	REGION	TOTAL_VENTAS
1	TOTAL AUTOS SCANNING MEXICO	5521492.32
2	TOTAL AUTOS AREA 2	1188976.15
3	TOTAL AUTOS AREA 5	1163335.538
4	TOTAL AUTOS AREA 6	983057.571
5	TOTAL AUTOS AREA 1	714249.979
6	TOTAL AUTOS AREA 4	677435.996
7	NULL	NULL



Regiones con mayor desempeño

Se identificaron las regiones con mayor volumen de ventas, permitiendo detectar las zonas con mejor desempeño comercial.



2. TOP PRODUCTOS

```
1 - SELECT TOP 10
2     NOMBRE_PRODUCTO,
3     SUM(CAST(TOTAL_VALUE_SALES AS FLOAT)) AS TOTAL_VENTAS
4 FROM FACT_SALES
5 GROUP BY NOMBRE_PRODUCTO
6 ORDER BY TOTAL_VENTAS DESC;
```

Resultados Mensajes

	NOMBRE_PRODUCTO	TOTAL_VENTAS
1	CLORALEX EL RENDIDOR BOT PLAST 3750ML NAL 00000750000	1146496.632
2	CLORALEX EL RENDIDOR BOT PLAST 2500ML NAL 00000750000	1139233.387
3	CLORALEX EL RENDIDOR BOT PLAST 950ML NAL 00000750010	656545.668
4	BLACATEL CONCENTRADO BOT PLAST 3750ML NAL 75010705	491075.222
5	CLORALEX REGULAR CONCENTRADO BOT PLAST 3800ML 750106...	399994.779
6	CLORALEX ULTRAGEL CLORO EN GEL CONCENTRADO 950ML NAL...	241281.14
7	CLORALEX EL RENDIDOR BOT 1800-1000ML 2LT 750102540514	241498.884
8	CLORALEX ULTRAGEL CLORO GEL CONCENTRADO BOT 600 ML N...	235784.387
9	CLOROACCION EN GEL BOT 950ML 7501025405151	198011.454
10	CLORALEX CLORO EN GEL BP 2000ML 7501025405106	175110.993



Productos destacados

El análisis permitió identificar los productos con mayores ingresos acumulados dentro del periodo analizado.



HALLAZGOS PRINCIPALES



Se identificaron diferencias relevantes entre regiones.



Algunos productos concentran gran parte de las ventas.



SQL SERVER

Tendencias y Promedios – Parte 2

Las consultas SQL permitieron analizar el comportamiento temporal y calcular promedios para evaluar estabilidad y rendimiento comercial.

3. EVOLUCIÓN SEMANAL DE VENTAS

```
1 SELECT
2     WEEK,
3     SUM(CAST(TOTAL_VALUE_SALES AS FLOAT)) AS TOTAL_VENTAS
4 FROM FACT_SALES
5 GROUP BY WEEK,
6 ORDER BY WEEK;
```

Resultados	Mensajes
WEEK	TOTAL_VENTAS
1 10-22	101158.922
2 01-23	151530.044
3 02-23	148653.881
4 03-23	155505.082
5 04-23	155510.085
6 05-23	135774.212
7 06-23	133365.717
8 06-23	123965.617
9 04-22	136841.767
10 05-22	129841.767
11 05-23	142250.682
12 06-23	133952.288
13 07-22	126267.77



Tendencia temporal

La evolución semanal de ventas permitió observar el comportamiento temporal y detectar periodos de mayor demanda.

4. PROMEDIO SEMANAL POR REGIÓN

```
1 SELECT
2     REGION,
3     AVG(CAST(TOTAL_INT_AVG_WEEKLY_SALES AS FLOAT)) AS PROMEDIO_SEMANAL
4 FROM FACT_SALES
5 GROUP BY REGION
6 ORDER BY PROMEDIO_SEMANAL DESC;
```

Resultados	Mensajes
REGION	PROMEDIO_SEMANAL
1 TOTAL AUTOS AREA 3	10.9202317635286
2 TOTAL AUTOS SCANNING MEXICO	10.3623576676332
3 TOTAL AUTOS AREA 5	10.5639064000236
4 TOTAL AUTOS AREA 6	10.8516284573814
5 TOTAL AUTOS AREA 2	9.785909598147596
6 TOTAL AUTOS AREA 4	9.0007753353541
7 TOTAL AUTOS AREA 1	9.16557101573774
8 NULL	NULL



Rendimiento promedio

Se calcularon promedios semanales por región para evaluar estabilidad y comparar el desempeño comercial entre zonas.



HALLAZGOS PRINCIPALES



Existen patrones temporales semanales en las ventas.



Las ventas muestran periodos de mayor demanda.



Los promedios regionales muestran estabilidad comercial.



LIMPIEZA Y TRANSFORMACIÓN DE DATOS CON PYTHON

Los datos fueron cargados y procesados utilizando Pandas en Python. Se realizaron tareas de limpieza, validación de tipos de datos y transformación de variables para facilitar el análisis posterior.



¿Qué se hizo?

Se cargaron los datos de diferentes fuentes y se unificaron en un solo DataFrame para su análisis.



¿Qué se revisó?

Se validaron valores nulos, registros duplicados y tipos de datos para asegurar la calidad de la información.



¿Qué se transformó?

Se convirtieron columnas numéricas y se creó una variable adicional para analizar el valor promedio por unidad vendida.



Objetivo

Preparar la información de ventas para un análisis posterior, validando su integridad y generando métricas derivadas relevantes.



1. CARGA DE DATOS

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

[2]: fact_sales = pd.read_csv("C:\\Users\\alive\\Downloads\\FACT_SALES.csv")
dim_category = pd.read_csv("C:\\Users\\alive\\Downloads\\DIM_CATEGORY.csv")
dim_product = pd.read_excel("C:\\Users\\alive\\Downloads\\DIM_PRODUCT.xlsx")
dim_calendar = pd.read_excel("C:\\Users\\alive\\Downloads\\DIM_CALENDAR.xlsx")
dim_segment = pd.read_excel("C:\\Users\\alive\\Downloads\\DIM_SEGMENT.xlsx")

[3]: fact_sales.head()
```

- Se cargaron las tablas de ventas y dimensiones desde archivos CSV y Excel para integrarlas en un solo DataFrame.



2. REVISIÓN DE NULOS Y DUPLICADOS

```
[4]: fact_sales.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 122002 entries, 0 to 122001
Data columns (total 6 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   WEEK                122002 non-null  object 
 1   ITEM_CODE           122002 non-null  object 
 2   TOTAL_UNIT_SALES    122002 non-null  float64
 3   TOTAL_VALUE_SALES   122002 non-null  float64
 4   TOTAL_UNIT_AVG_WEEKLY_SALES 122002 non-null  float64
 5   REGION              122002 non-null  object 
dtypes: float64(3), object(3)
memory usage: 5.6+ MB
```

- Se verificó la calidad de los datos revisando valores nulos y registros duplicados para asegurar la integridad del dataset.

	WEEK	ITEM_CODE	TOTAL_UNIT_SALES	TOTAL_VALUE_SALES	TOTAL_UNIT_AVG_WEEKLY_SALES	REGION
0	34-22	7501058792808892	0.006	0.139	1.000	TOTAL AUTOS AREA 5
1	34-22	7501058715683	0.487	116.519	2.916	TOTAL AUTOS AREA 5
2	34-22	7702366213774	1.391	68.453	5.171	TOTAL AUTOS AREA 5
3	34-22	75010587164622	0.022	1.481	1.883	TOTAL AUTOS AREA 5
4	34-22	7501058784353	2.037	162.839	5.375	TOTAL AUTOS AREA 5

jupyter Untitled32 Last Checkpoint: 16 minutes ago

```
[5]: fact_sales.isnull().sum()

WEEK                0
ITEM_CODE           0
TOTAL_UNIT_SALES    0
TOTAL_VALUE_SALES   0
TOTAL_UNIT_AVG_WEEKLY_SALES 0
REGION              0
dtype: int64
```

jupyter Untitled32 Last Checkpoint: 8 minutes ago

```
[6]: fact_sales.duplicated().sum()

[6]: 0
```

Resumen de revisión

- No se encontraron valores nulos en el dataset.
- No se identificaron registros duplicados.



HALLAZGOS PRINCIPALES



Los datos se cargaron correctamente desde diferentes fuentes.



No se detectaron valores nulos ni registros duplicados.



La información está lista para transformación y análisis posterior.



LIMPIEZA Y TRANSFORMACIÓN DE DATOS CON PYTHON

Se transformaron variables numéricas y se creó una variable adicional para analizar el valor promedio por unidad vendida. Además, se generaron métricas derivadas para el análisis.

3 TRANSFORMACIÓN DE VARIABLES



Se convirtieron columnas a tipo numérico y se creó la variable VALUE_PER_UNIT.

```
jupyter Untitled32 Last Checkpoint: 18 minutes ago
File Edit View Run Kernel Settings Help
Python [conda env:base] Anaconda Toolbox

[2]: fact_sales["TOTAL_UNIT_SALES"] = pd.to_numeric(fact_sales["TOTAL_UNIT_SALES"], errors='coerce')
fact_sales["TOTAL_VALUE_SALES"] = pd.to_numeric(fact_sales["TOTAL_VALUE_SALES"], errors='coerce')
fact_sales["TOTAL_UNIT_AVG_WEEKLY_SALES"] = pd.to_numeric(
    fact_sales["TOTAL_UNIT_AVG_WEEKLY_SALES"],
    errors='coerce'
)

[3]: fact_sales = fact_sales.dropna(subset=[
    "TOTAL_UNIT_SALES",
    "TOTAL_VALUE_SALES",
    "TOTAL_UNIT_AVG_WEEKLY_SALES"
])

[4]: fact_sales["VALUE_PER_UNIT"] = fact_sales["TOTAL_VALUE_SALES"] / fact_sales["TOTAL_UNIT_SALES"]
fact_sales["VALUE_PER_UNIT"] = fact_sales["VALUE_PER_UNIT"].replace([np.inf, -np.inf], np.nan)
fact_sales.head()
```

	WEEK	ITEM_CODE	TOTAL_UNIT_SALES	TOTAL_VALUE_SALES	TOTAL_UNIT_AVG_WEEKLY_SALES	REGION	VALUE_PER_UNIT
0	34-22	75010587926808P2	0.006	0.139	1.000	TOTAL AUTOS AREA 5	23.166667
1	34-22	75010587156883	0.487	116.519	2.916	TOTAL AUTOS AREA 5	239.258727
2	34-22	77023626137774	1.391	68.453	5.171	TOTAL AUTOS AREA 5	49.211559
3	34-22	75010587166422	0.022	1.481	1.833	TOTAL AUTOS AREA 5	67.318182
4	34-22	75010587044353	2.037	162.839	5.375	TOTAL AUTOS AREA 5	79.798959

4 MÉTRICAS GENERADAS



Se generaron estadísticas descriptivas para el análisis de VALUE_PER_UNIT.

```
jupyter Untitled32 Last Checkpoint: 18 minutes ago
File Edit View Run Kernel Settings Help
Python [conda env:base] Anaconda Toolbox

[11]: fact_sales[["VALUE_PER_UNIT", "TOTAL_VALUE_SALES", "TOTAL_UNIT_SALES"]].describe()
```

	TOTAL_UNIT_SALES	TOTAL_VALUE_SALES	TOTAL_UNIT_AVG_WEEKLY_SALES	VALUE_PER_UNIT
count	122002.000000	122002.000000	122002.000000	121924.000000
mean	3.211097	90.513761	10.099904	55.123670
std	14.490900	350.236605	22.650142	50.783350
min	0.000000	0.001000	0.042000	0.543455
25%	0.063000	2.652000	2.318000	20.922490
50%	0.367000	16.812000	3.993500	36.668364
75%	1.520000	62.991500	8.898000	69.313511
max	584.681000	12236.795000	784.003000	298.300000

```
[12]: fact_sales.to_csv("FACT_SALES_LIMPIO.csv", index=False)

'FACT_SALES_LIMPIO.csv'
```



HALLAZGOS PRINCIPALES



Se creó la variable VALUE_PER_UNIT para analizar el valor promedio por unidad vendida.



Se generaron métricas descriptivas que ayudan a entender la distribución de los datos.



La transformación permitió generar métricas derivadas y validar la consistencia de más de 120 mil registros de ventas.



ANÁLISIS EXPLORATORIO DE DATOS (EDA)

SLIDE 1


Se realizó un análisis exploratorio de datos (EDA) para identificar distribuciones, tendencias, valores atípicos y patrones generales dentro de la información de ventas.

1



DISTRIBUCIÓN DE VENTAS

Se analizó la distribución de la variable `TOTAL_VALUE_SALES`.




La distribución de ventas muestra concentración en valores bajos y presencia de valores atípicos.

2



VENTAS POR REGIÓN

Se exploró qué regiones generan mayores ventas.




En el total por región permite identificar diferencias relevantes en el desempeño comercial entre zonas.

3



TENDENCIA SEMANAL DE VENTAS

Se analizó la evolución de las ventas a lo largo del tiempo.



La tendencia semanal permitió observar variaciones en el comportamiento de ventas a lo largo del tiempo.



ANÁLISIS EXPLORATORIO DE DATOS (EDA)


SLIDE 2

4



IDENTIFICACIÓN DE VALORES ATÍPICOS

Se utilizaron boxplots para detectar posibles valores atípicos en ventas totales.




El boxplot revela valores atípicos en ventas, lo que indica productos o registros con comportamiento superior al promedio.

5



TOP 10 PRODUCTOS POR VENTAS

Se identificaron los productos que más ingresos generan dentro del dataset.



El análisis de productos muestra concentración de ventas en ciertos artículos clave.



HALLAZGOS PRINCIPALES



Valores atípicos detectados

Se identificaron registros con ventas totales significativamente superiores al resto, lo que podría indicar oportunidades o anomalías.



Concentración de ventas

Un pequeño grupo de productos genera la mayor parte de los ingresos totales.



Tendencia de crecimiento

Las ventas muestran una tendencia positiva sostenida, con un aumento significativo en las últimas semanas.



Diversidad regional

Las ventas están distribuidas en varias regiones, aunque algunas concentran un mayor porcentaje del total.



Oportunidades de optimización

Existen productos con bajo rendimiento que podrían optimizarse o replantearse dentro de la estrategia comercial.



DASHBOARD INTERACTIVO EN LOOKER STUDIO

Se desarrolló un dashboard interactivo para visualizar indicadores clave de ventas, tendencias semanales, distribución regional y productos con mayor desempeño.

1 VISUALIZACIÓN EN DASHBOARD




Se integraron métricas y gráficos para analizar el comportamiento.

Unidad Total
10.003.171.510


Unidades Vendidas
390.186.330

REGION


Ventas por Región



Tendencia Semanal de Ventas



Top 10 Productos



2 FILTROS Y MÉTRICAS DINÁMICAS



El dashboard permitió explorar indicadores comerciales mediante filtros.



Indicadores clave

Se visualizaron ventas totales, unidades vendidas, distribución regional, tendencias semanales y top de productos.



Análisis interactivo

El uso de filtros dinámicos permitió segmentar la información y observar el comportamiento comercial por región.



Toma de decisiones

La visualización facilitó la interpretación de patrones y apoyó decisiones estratégicas basadas en datos.



HALLAZGOS PRINCIPALES



Se integraron filtros dinámicos para explorar métricas comerciales.



El dashboard muestra tendencias semanales y desempeño regional.



La visualización permite comparar productos con mayor participación.



MODELO PREDICTIVO DE VENTAS

SLIDE 2A

Se implementó un modelo de Machine Learning utilizando regresión lineal para predecir el valor total de ventas a partir de variables de comportamiento comercial.



¿QUÉ SE HIZO?

Se implementó un modelo de Machine Learning utilizando regresión lineal para predecir el comportamiento de ventas a partir de variables numéricas y métricas históricas.



¿QUÉ PERMITIÓ?

El modelo permitió generar predicciones de ventas confiables y monitorear métricas clave para apoyar el análisis y la toma de decisiones basadas en datos.

1

IMPLEMENTACIÓN DEL MODELO

```
# Importar librerías
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, r2_score

# 1. Cargar datos
fact_sales = pd.read_csv("fact_sales_limpio.csv")

# 2. Definir variables
X = fact_sales[ 'total_unit_sales', 'total_value_sales',
               'total_int_avg_weekly_sales', 'region' ]
y = fact_sales[ 'total_ventas' ]

# 3. Dividir datos (80% entrenamiento / 20% test)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

# 4. Entrenar modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)
```

2

EJECUCIÓN Y EVALUACIÓN

```
# Predicción
y_pred = modelo.predict(X_test)

# Evaluar rendimiento (MAE)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

# Mostrar métricas
print("Error absoluto medio (MAE):", mae)
print("R² Score:", r2)

# Visualizar resultados (opcional)
resultado = pd.DataFrame({
    "Real": y_test,
    "Predicho": y_pred
})
resultado.head()

# Gráfica de dispersión (opcional si se necesita)
# plt.scatter(...)
```


3

RESULTADOS OBTENIDOS



Se utilizó regresión lineal para predecir las ventas totales. El modelo fue entrenado con el 80% de los datos y evaluado con el 20% restante.

Las métricas y el gráfico de dispersión resumen el desempeño del modelo frente a los valores reales.



HALLAZGOS PRINCIPALES

- ✓ El modelo de regresión lineal es efectivo para estimar las ventas.
- ✓ Existe una relación significativa entre las variables y las ventas.
- ✓ Las predicciones muestran un bajo error promedio.
- ✓ El modelo puede servir como base para futuras mejoras y optimizaciones.



Nota: La gráfica de dispersión se debe insertar en el espacio cuadrado señalado.

ALMACENAMIENTO Y CONSULTAS SQL EN AWS (S3 & ATHENA)



En AWS se utilizó Amazon S3 para almacenar los archivos y AWS Athena para realizar consultas SQL directamente en la nube.

Se creó una tabla externa conectada al archivo FACT SALES LIMPIO.csv, permitiendo consultar y analizar más de 120 mil registros de ventas en un entorno Big Data.



¿Qué se hizo?

Se almacenó el archivo de ventas limpio (FACT_SALES_LIMPIO.csv) en Amazon S3 y se creó una tabla externa en AWS Athena.



¿Cómo se conectó?

Se definió como origen de datos el catálogo AwsDataCatalog y la base de datos proyecto_final_ventas. Luego, se creó una tabla externa sobre el archivo CSV en S3.



¿Para qué sirve?

Permite consultar directamente más de 120 mil registros de ventas con SQL, sin necesidad de mover los datos, aprovechando la escalabilidad y el rendimiento de la nube.



HALLAZGOS PRINCIPALES



Se almacenaron los datos en Amazon S3 garantizando disponibilidad y escalabilidad.



Se creó una tabla externa en AWS Athena para consultar más de 120 mil registros sin mover los datos.



Las consultas SQL en Athena permiten análisis ágiles y eficientes en un entorno Big Data.

CONSULTAS EJECUTADAS EN AWS ATHENA

1. CONSULTA DE DATOS

2. VENTAS TOTALES POR REGIÓN

3. TOP PRODUCTOS POR VENTAS



HALLAZGOS CLAVE

A partir del análisis de ventas realizado utilizando SQL en AWS Athena y los datos almacenados en Amazon S3, se obtuvieron los siguientes hallazgos clave que permiten comprender el comportamiento comercial y la calidad de la información.



1 REGIONES CON MAYOR PARTICIPACIÓN EN LAS VENTAS

Se identificaron regiones con mayor participación en las ventas totales, mostrando diferencias relevantes en el desempeño comercial.



2 PRODUCTOS QUE CONCENTRAN INGRESOS

Algunos productos concentran una proporción significativa de ingresos dentro del dataset analizado.



3 VARIACIONES SEMANALES EN LAS VENTAS

Las ventas presentan variaciones semanales constantes, permitiendo identificar tendencias temporales y periodos de mayor demanda.



4 CALIDAD DE LOS DATOS ASEGURADA

El proceso de limpieza y transformación de datos permitió trabajar con información consistente para análisis y modelos predictivos.



5 VISUALIZACIÓN EFECTIVA CON DASHBOARD

El dashboard interactivo facilitó la visualización dinámica de métricas clave y comportamiento comercial.



CONCLUSIONES PRINCIPALES



Las regiones presentan diferencias relevantes en su desempeño comercial.



Un grupo reducido de productos concentra la mayor parte de los ingresos.



Las ventas muestran tendencias semanales claras y periodos de mayor demanda.



La calidad de los datos es óptima para análisis y modelos predictivos.



El dashboard permite una visualización clara y toma de decisiones ágil.



RECOMENDACIONES

Con base en el análisis realizado de las ventas utilizando SQL en AWS Athena y los datos almacenados en Amazon S3, se proponen las siguientes recomendaciones para potenciar el desempeño comercial y la gestión de datos.



1 FORTALECER ESTRATEGIAS COMERCIALES EN LAS REGIONES CON MAYOR DESEMPEÑO

Fortalecer estrategias comerciales en las regiones con mayor desempeño para maximizar el crecimiento de ventas.



2 IMPLEMENTAR MONITOREO CONSTANTE SOBRE LOS PRODUCTOS CON MAYOR PARTICIPACIÓN

Implementar monitoreo constante sobre los productos con mayor participación para optimizar inventario y distribución.



3 ANALIZAR CON MAYOR DETALLE LAS VARIACIONES SEMANALES DE VENTAS

Analizar con mayor detalle las variaciones semanales de ventas para detectar patrones de comportamiento y oportunidades comerciales.



4 CONTINUAR UTILIZANDO HERRAMIENTAS DE ANÁLISIS Y VISUALIZACIÓN DE DATOS

Continuar utilizando herramientas de análisis y visualización de datos para mejorar la toma de decisiones estratégicas.



5 IMPLEMENTAR MODELOS PREDICTIVOS MÁS AVANZADOS

Implementar modelos predictivos más avanzados para mejorar la estimación de ventas futuras y apoyar la planeación comercial.



BENEFICIOS ESPERADOS



Incremento en el crecimiento de ventas y participación de mercado.



Mejor gestión de inventarios y distribución de productos clave.



Detección oportuna de patrones y oportunidades comerciales relevantes.



Toma de decisiones más informadas y estratégicas basadas en datos.



Mayor precisión en las proyecciones y planeación comercial futura.



FUTURAS MEJORAS

Para continuar potenciando el análisis de ventas y la gestión de datos en AWS, se proponen las siguientes mejoras que permitirán escalar el proyecto y obtener mayor valor del entorno Big Data.



1 INCORPORAR MODELOS DE MACHINE LEARNING MÁS AVANZADOS

Incorporar modelos de Machine Learning más avanzados para mejorar la precisión de las predicciones de ventas.



2 AUTOMATIZAR PROCESOS DE LIMPIEZA Y TRANSFORMACIÓN DE DATOS

Automatizar procesos de limpieza y transformación de datos mediante pipelines en la nube.



3 INTEGRAR NUEVAS FUENTES DE INFORMACIÓN

Integrar nuevas fuentes de información para enriquecer el análisis comercial y estratégico.



4 DESARROLLAR DASHBOARDS EN TIEMPO REAL

Desarrollar dashboards en tiempo real para monitorear indicadores clave de desempeño.



5 IMPLEMENTAR PROCESOS ETL MÁS ROBUSTOS

Implementar procesos ETL más robustos utilizando servicios cloud como AWS Glue y Athena.



BENEFICIOS ESPERADOS



Mayor precisión en las predicciones de ventas.



Procesos más eficientes y menos propensos a errores.



Análisis más completo y estratégico con datos enriquecidos.



Monitoreo continuo y oportuno de indicadores clave.



Infraestructura escalable y procesos ETL más confiables.



CIERRE

El proyecto permitió generar valor a partir de los datos, transformándolos en información clave para comprender el comportamiento comercial y apoyar la toma de decisiones estratégicas.



El desarrollo de este proyecto permitió **integrar herramientas de análisis de datos, visualización y Machine Learning** para obtener **insights estratégicos** sobre el comportamiento de ventas.



La combinación de **Excel, SQL, Python, Looker Studio y AWS** facilitó la construcción de un **flujo completo de análisis** orientado a la toma de decisiones basada en datos.



VALOR GENERADO



Mayor comprensión del comportamiento de ventas.



Información confiable para decisiones estratégicas.



Procesos de análisis más eficientes y escalables.



Base sólida para modelos predictivos y proyecciones.



Mayor valor competitivo a partir de los datos.